Projekt 2

Analiza częstotliwościowa sygnałów audio[1]

Kacper Tomczyk
Nr albumu: 333166
Warszawa, 30 kwietnia 2026

[1] Kod źródłowy projektu: github.com/kacpert20/AUDIO2

Opis aplikacji

Aplikacja desktopowa zrealizowana w języku Python (wersja 3.10+) z graficznym interfejsem użytkownika opartym na bibliotece **PyQt6** oraz **pyqtgraph** do wizualizacji wykresów w czasie rzeczywistym. Obliczenia matematyczne wykonywane są przy użyciu biblioteki **NumPy** – wszystkie algorytmy (okna, FFT, spektrogram, parametry dziedziny częstotliwości, cepstrum) zostały zaimplementowane samodzielnie, bez użycia gotowych funkcji analitycznych z bibliotek takich jak SciPy.

Projekt podzielony jest na trzy moduły:

- `audio_io.py` – wczytywanie plików `.wav` przy użyciu standardowych bibliotek Pythona (`wave`, `struct`); obsługa plików mono i stereo (stereo automatycznie konwertowane do mono);
- `freq_engine.py` – silnik matematyczny: funkcje okienkowe, FFT, spektrogram, parametry częstotliwościowe na poziomie ramki, cepstrum i estymacja F0;
- `freq_gui.py` – interfejs użytkownika podzielony na pięć zakładek.

Interfejs aplikacji przedstawiono na rysunku 1.

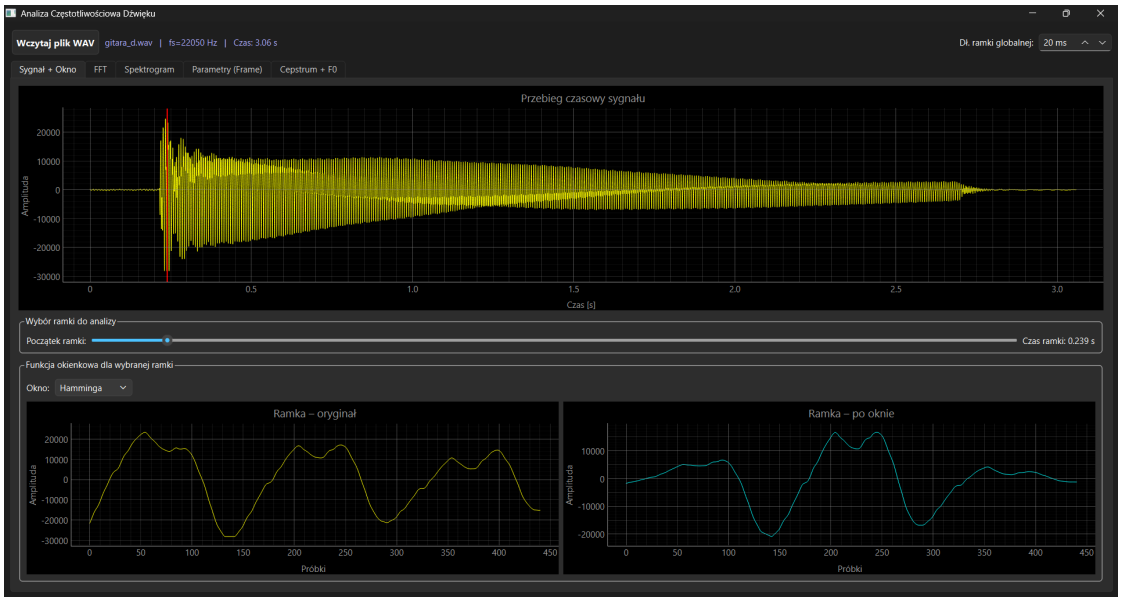

Rysunek 1: Widok ogólny aplikacji po wczytaniu pliku `gitara_d.wav`. Widoczna zakładka *Sygnał + Okno* z przebiegiem czasowym i widokiem wybranej ramki przed i po zastosowaniu okna Hamminga.

Funkcje okienkowe

Bezpośrednie wycięcie skończonej ramki sygnału odpowiada pomnożeniu go przez okno prostokątne, co w dziedzinie częstotliwości powoduje splot widma z funkcją *sinc* i pojawienie się tzw. listków bocznych. Zastosowanie okien wygładzających redukuje ten efekt kosztem nieznacznego poszerzenia listka głównego.

Zaimplementowano pięć funkcji okienkowych. Dla ramki o długości N próbek i indeksie $n \in \{0, 1, \ldots, N-1\}$:

Okno prostokątne:

$$w(n) = 1 \tag{1}$$

Okno trójkątne (Bartlett):

$$w(n) = 1 - \frac{|2n - (N-1)|}{N-1} \tag{2}$$

Okno Hamminga:

$$w(n) = 0{,}54 - 0{,}46 \cdot \cos\left(\frac{2\pi n}{N-1}\right) \tag{3}$$

Okno Hanna (von Hann):

$$w(n) = 0{,}5 \cdot \left(1 - \cos\left(\frac{2\pi n}{N-1}\right)\right) \tag{4}$$

Okno Blackmana:

$$w(n) = 0{,}42 - 0{,}5 \cdot \cos\left(\frac{2\pi n}{N-1}\right) + 0{,}08 \cdot \cos\left(\frac{4\pi n}{N-1}\right) \tag{5}$$

Na rysunku 2 porównano ten sam fragment sygnału (`gitara_d.wav`) przed i po zastosowaniu okna Hamminga, a na rysunku 3 przedstawiono wpływ wyboru okna na widmo FFT.

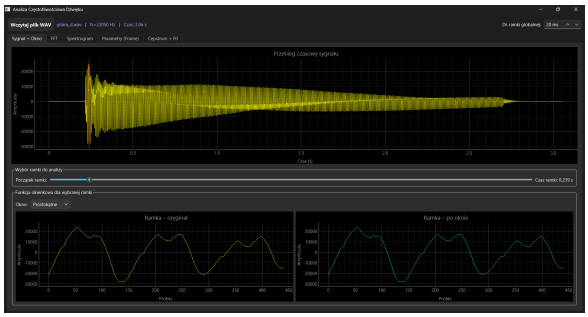

(a) Okno prostokątne

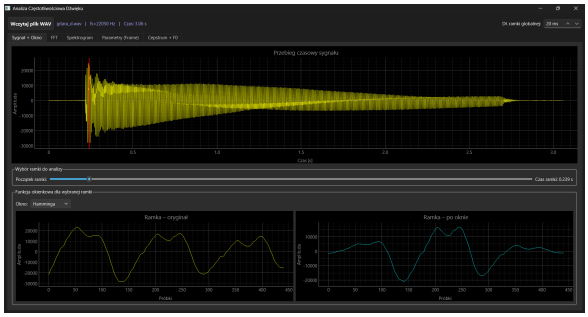

(b) Okno Hamminga

Rysunek 2: Ramka sygnału `gitara_d.wav` (t = 0,2 s) przed i po zastosowaniu okna. Okno Hamminga wygładza krawędzie ramki, co redukuje listki boczne w widmie.

Transformata Fouriera (FFT)

Do obliczenia widma amplitudowego ramki sygnału wykorzystano jednostronną dyskretną transformatę Fouriera (DFT) obliczaną algorytmem FFT:

$$S_n(k) = \sum_{m=0}^{N-1} s_n(m) \cdot w(m) \cdot e^{-j2\pi km/N}, \quad k = 0, 1, \ldots, \left\lfloor \frac{N}{2} \right\rfloor \tag{6}$$

Wynik prezentowany jest w skali decybelowej:

$$|S_n(k)|_{\mathrm{dB}} = 20 \cdot \log_{10}\left(\frac{|S_n(k)|}{N}\right) \tag{7}$$

Aplikacja wyświetla jednocześnie widmo bez okna (żółte) oraz z wybranym oknem (niebieskie), umożliwiając bezpośrednie porównanie.

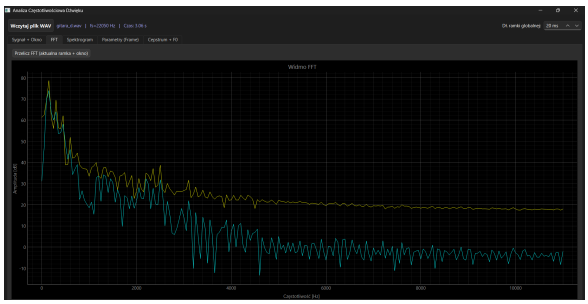

(a) `gitara_d.wav` – wyraźna struktura harmoniczna

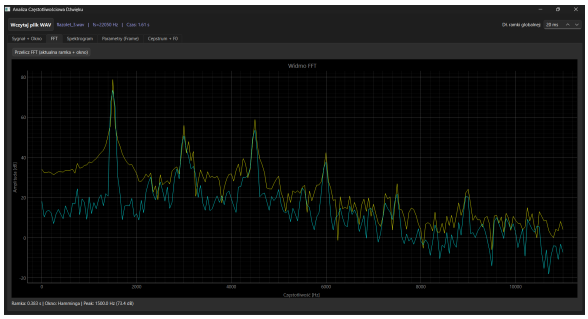

(b) `flazolet_3.wav` – dominujący pojedynczy pik

Rysunek 3: Porównanie widma FFT dla dwóch różnych sygnałów. Widmo gitary charakteryzuje się serią równoodległych pików harmonicznych, natomiast widmo fletu jest quasi-sinusoidalne.

Spektrogram

Spektrogram jest reprezentacją sygnału w trzech wymiarach: czas, częstotliwość i amplituda (zakodowana kolorem). Zaimplementowany został samodzielnie jako sekwencja ramek z nakładaniem (*overlapping*):

$$\text{krok} = N_w \cdot \left(1 - \frac{\text{overlap}}{100}\right) \tag{8}$$

gdzie N_w to rozmiar ramki w próbkach, a overlap $\in [0\%, 90\%]$. Dla każdej ramki obliczana jest FFT z wybranym oknem, a wynik zapisywany w macierzy (n_ramek $\times$ n_freq) i wyświetlany jako obraz z mapą kolorów *inferno*.

Rozdzielczość częstotliwościowa spektrogramu wynosi:

$$\Delta f = \frac{f_s}{N_w} \tag{9}$$

Istnieje kompromis między rozdzielczością czasową a częstotliwościową – dłuższa ramka poprawia rozdzielczość częstotliwościową kosztem czasowej. Większy overlap poprawia gęstość próbkowania w czasie bez zmiany Δf.

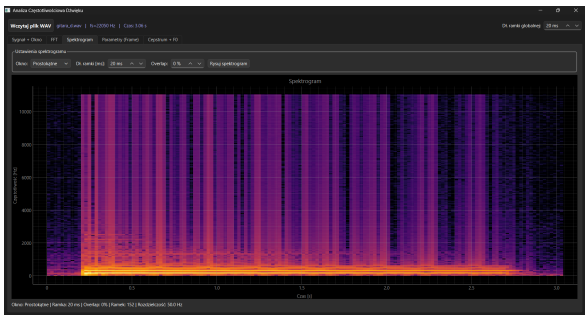

(a) Ramka 20 ms, overlap 0% – $\Delta f = 50$ Hz

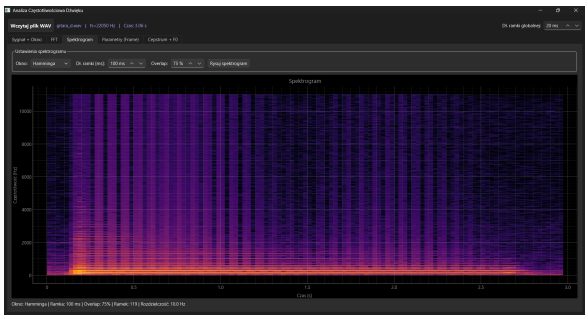

(b) Ramka 100 ms, overlap 75% – $\Delta f = 10$ Hz

Rysunek 4: Spektrogram sygnału `gitara_d.wav` przy różnych parametrach. Przy dłuższej ramce harmoniczne struny D ($f_0 \approx 147$ Hz) są wyraźnie widoczne jako osobne poziome paski.

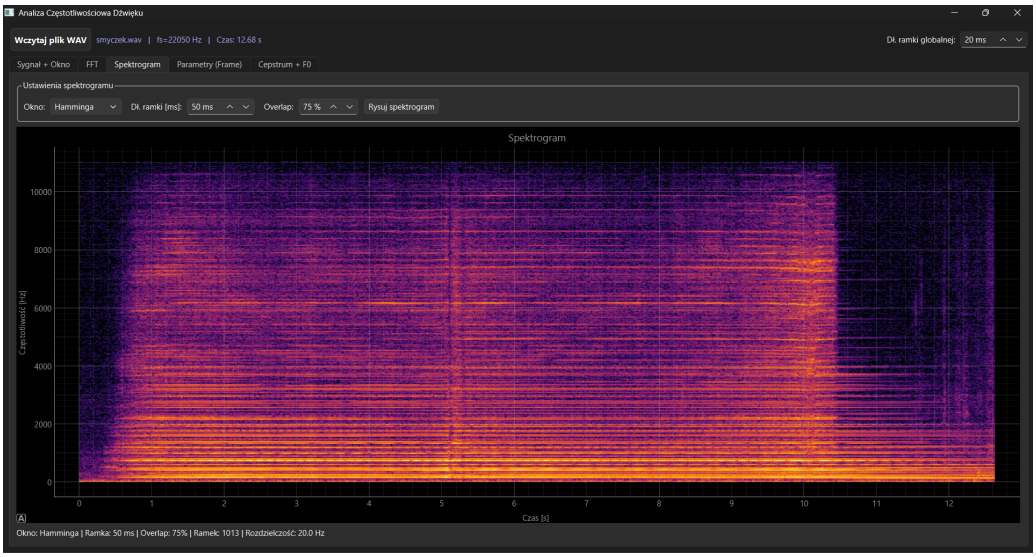

Rysunek 5: Spektrogram nagrania `smyczek.wav` (ramka 50 ms, overlap 75%, okno Hamminga). Widoczne wyraźne zmiany charakteru widma w czasie odpowiadające przejściom między kolejnymi strunami. Gęsty szum między harmonicznymi wynika z nieregularnego tarcia słabo nasymarowanego smyczka.

Parametry częstotliwościowe

Dla każdej ramki sygnału obliczane są następujące parametry dziedziny częstotliwości, gdzie $S_n(k)$ oznacza widmo n-tej ramki, f_k to odpowiadająca mu częstotliwość, a N to liczba próbek widma.

Głośność z widma (Volume):

$$\mathrm{Vol}(n) = \sqrt{\frac{1}{N}\sum_{k=0}^{N-1} S_n^2(k)} \tag{10}$$

Centroid częstotliwościowy (FC):

$$\mathrm{FC}(n) = \frac{\sum_k f_k \cdot S_n^2(k)}{\sum_k S_n^2(k)} \tag{11}$$

Centroid reprezentuje „środek ciężkości"mocy widmowej. Wysokie FC odpowiada sygnałom o dużej energii w wysokich częstotliwościach.

Efektywna szerokość pasma (BW):

$$\mathrm{BW}(n) = \sqrt{\frac{\sum_k (f_k - \mathrm{FC}(n))^2 \cdot S_n^2(k)}{\sum_k S_n^2(k)}} \tag{12}$$

Współczynnik energii pasma (ERSB):

Cały zakres częstotliwości podzielony jest na trzy pasma odpowiadające pasm krytycznym modelu słuchu człowieka (filtry ślimakowe):

$$\mathrm{ERSB}_b(n) = \frac{\sum_{k:f_k \in B_b} S_n^2(k)}{\sum_k S_n^2(k)} \tag{13}$$

gdzie $B_1 = [0, 630)$ Hz, $B_2 = [630, 1720)$ Hz, $B_3 = [1720, 4400)$ Hz.

Miara płaskości widmowej (SFM):

$$\mathrm{SFM}(n) = \frac{\exp\left(\frac{1}{N}\sum_k \ln S_n^2(k)\right)}{\frac{1}{N}\sum_k S_n^2(k)} \tag{14}$$

SFM bliski 1 oznacza widmo zbliżone do białego szumu. Sygnały tonalne (instrumenty muzyczne) mają SFM znacznie poniżej 1.

Spektralny współczynnik szczytu (SCF):

$$\mathrm{SCF}(n) = \frac{\max_k S_n^2(k)}{\frac{1}{N}\sum_k S_n^2(k)} \tag{15}$$

(a) `gitara_d.wav`

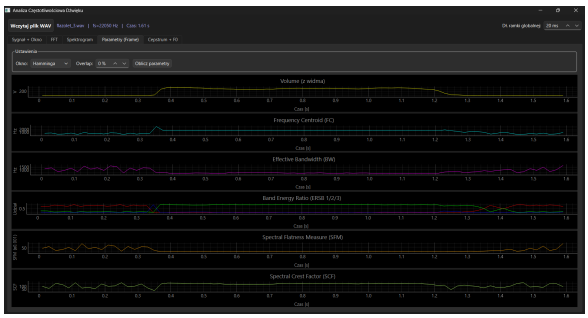

(b) `flazolet_3.wav`

Rysunek 6: Parametry częstotliwościowe na poziomie ramki dla dwóch sygnałów. Dla gitary FC maleje w czasie (zanikanie wyższych harmonicznych), natomiast dla fletu FC jest stabilne przez cały czas trwania dźwięku.

Cepstrum i estymacja F0

Cepstrum rzeczywiste zdefiniowane jest jako:

$$C(\tau) = \left|\mathcal{F}^{-1}\{\log|\mathcal{F}\{s(t)\}|\}\right| \tag{16}$$

Oś rzędnych cepstrum nosi nazwę *quefrency* i wyraża się w próbkach (lub sekundach). Periodyczna struktura harmoniczna widma sygnału dźwięcznego objawia się jako wyraźny pik w cepstrum przy quefrency $\tau_{\max}$ odpowiadającym okresowi tonu podstawowego. Ton podstawowy estymowany jest jako:

$$f_0 = \frac{f_s}{\tau_{\max}} \tag{17}$$

Poszukiwanie piku ograniczone jest do przedziału $[f_s/f_{\max},\ f_s/f_{\min}]$ próbek, gdzie $f_{\min}$, $f_{\max}$ to oczekiwany zakres F0 (domyślnie 50–400 Hz).

Warunek dźwięczności: pik cepstrum musi przekraczać 2,5-krotną średnią wartość cepstrum w przeszukiwanym przedziale. Ramki niespełniające warunku oznaczane są jako bezdźwięczne (F0 = 0).

(a) `gitara_d.wav` – wyraźny pik przy $\tau \approx 150$

(b) `flazolet_3.wav` – brak dominującego piku

Rysunek 7: Cepstrum rzeczywiste dla wybranej ramki. Gitara klasyczna wykazuje wyraźny pik przy quefrency $\tau \approx 150$ próbek, co odpowiada $f_0 = 22050/150 \approx 147$ Hz (struna D3). Dla fletu cepstrum jest płaskie – brak wielu harmonicznych uniemożliwia pewną estymację F0.

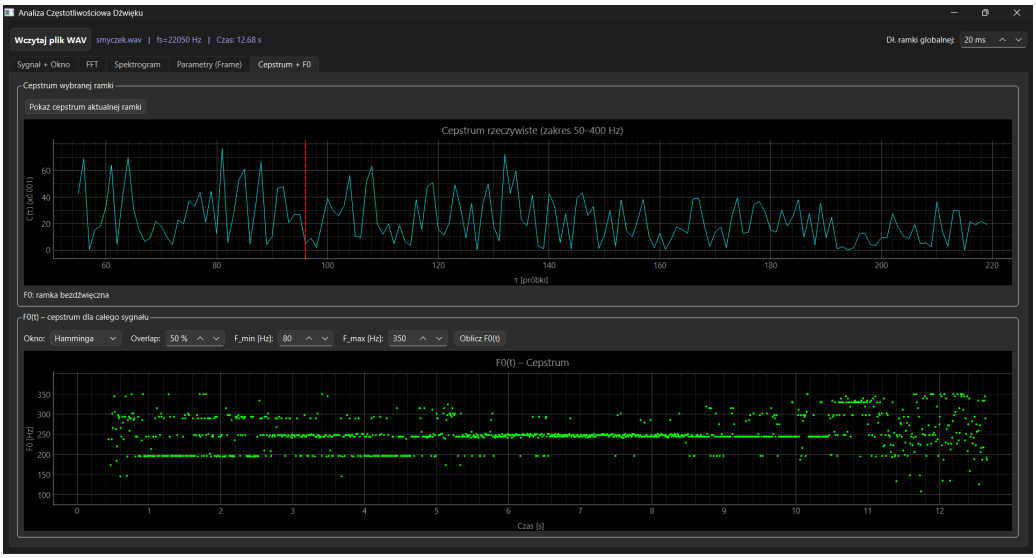

Rysunek 8: Wykres F0(t) dla nagrania `smyczek.wav` (okno Hamminga, overlap 50%, $f_{\min} = 80$ Hz, $f_{\max} = 350$ Hz). Widoczna dominująca linia przy ≈ 250 Hz odpowiadająca strunie B gitary ($f_0 = 247$ Hz). Rozproszenie punktów wynika z nieregularnego wzbudzania smyczkiem.

Analiza sygnałów mowy

Sygnały mowy charakteryzują się zmienną w czasie strukturą widmową, odpowiadającą kolejnym fonemom. W przeciwieństwie do instrumentów muzycznych widmo mowy nie wykazuje izolowanych pików harmonicznych – energia rozłożona jest szerzej i zmienia się dynamicznie.

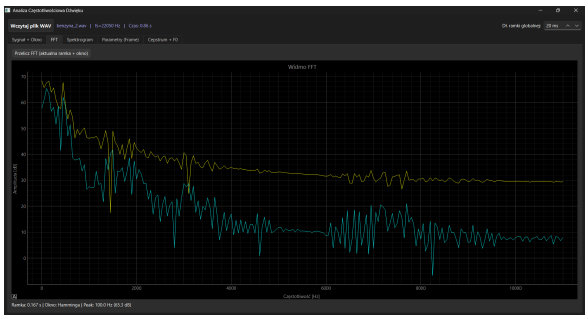

(a) FFT – brak izolowanych pików harmonicznych

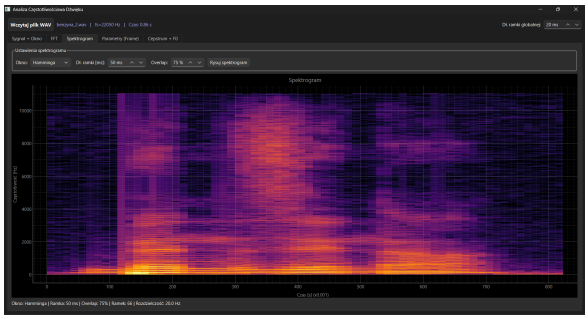

(b) Spektrogram – pionowe zmiany to fonemy

Rysunek 9: Analiza nagrania mowy `benzyna_2.wav`. Spektrogram (ramka 50 ms, overlap 75%, okno Hamminga) uwidacznia strukturę czasową słowa – przejścia między samogłoskami i spółgłoskami są wyraźnie widoczne jako pionowe zmiany intensywności.

Wnioski

Zrealizowana aplikacja umożliwia kompleksową analizę częstotliwościową sygnałów audio z interaktywnym doborem parametrów. Na podstawie przeprowadzonych eksperymentów sformułowano następujące obserwacje:

Wpływ funkcji okienkowej. Okno prostokątne powoduje wyraźne listki boczne w widmie FFT, utrudniając identyfikację słabszych harmonicznych. Okna Hamminga i Hanna oferują dobry kompromis między szerokością listka głównego a tłumieniem listków bocznych. Okno Blackmana zapewnia najlepsze tłumienie (>60 dB) kosztem najszerszego listka głównego.

Dobór parametrów spektrogramu. Dla sygnałów instrumentalnych (harmonicznych) optymalna długość ramki wynosi 50–100 ms, co zapewnia rozdzielczość częstotliwościową 10–20 Hz wystarczającą do rozróżnienia kolejnych harmonicznych. Overlap 50–75% poprawia ciągłość wizualną bez zmiany rozdzielczości. Krótka ramka (20 ms) jest niewystarczająca dla niskich tonów (struna D: $f_0 \approx 147$ Hz, okres $\approx 6{,}8$ ms – w ramce mieszczą się zaledwie 3 okresy).

Ograniczenia cepstrum. Metoda cepstrum działa dobrze dla sygnałów bogatych harmonicznie (mowa, instrumenty strunowe szarpane, smyczkowe). Dla sygnałów quasi-sinusoidalnych (flet prosty, flażolet gitarowy) brak wyraźnych harmonicznych uniemożliwia pewną estymację F0. Obserwowano również *błąd oktawy*: dla flażoletu gitarowego, gdzie fundamentalna jest tłumiona techniką gry, algorytm wskazywał $\tau_{\max}$ odpowiadające połowie rzeczywistego F0. Dla akordów (wiele fundamentów jednocześnie) metoda nie daje jednoznacznego wyniku.

Parametry ERSB. Pasma energii widmowej skutecznie różnicują badane sygnały: dla gitary klasycznej dominuje ERSB1 (0–630 Hz), dla fletu prostego – ERSB2 (630–1720 Hz), zaś dla nagrań mowy wartości ERSB są zmienne w czasie, odzwierciedlając dynamikę fonetyczną.

Centroid częstotliwościowy. Dla instrumentów szarpanych (gitara) FC maleje monotonicznie w czasie, co odzwierciedla szybsze zanikanie wyższych harmonicznych. Dla instrumentów dętych (flet) FC pozostaje stabilne przez cały czas trwania dźwięku.